

基于 Ranking 的贝叶斯序列推荐算法

何 慧

(江西师范大学 电子商务系,南昌 330022)

E-mail: hehui_1978@163.com

摘 要: 针对用户行为转移特性和缓解用户行为数据的稀疏性问题,提出了基于 Ranking 的贝叶斯序列推荐算法(SR-BPR)。SR-BPR 算法利用用户与商品的历史交互序列关系,构造行为转移三维张量,基于用户的转移概率,为每个用户构建商品偏好的偏序关系,最后利用贝叶斯 Ranking 优化算法进行张量分解,将用户和商品映射到高维空间,生成用户和商品的潜因子向量,通过用户和商品的潜因子向量内积预测用户对商品的喜好程度。利用 Book Crossing 数据集进行实验,实验结果表明,相比于传统的推荐算法,本文提出的 SR-BPR 算法在准确度上提升了 26%,在 20% 的训练样本 0.93% 的数据稠密度上,SR-BPR 算法 RMSE 误差率相比于传统算法降低了 11.23%。

关键词: 推荐算法;序列推荐;张量分解;贝叶斯网络

中图分类号: TP391

文献标识码: A

文章编号: 1000-1220(2018)07-1560-05

Ranking Based Bayesian Sequence Recommendation Algorithm

HE Hui

(Electronic Commerce Department of Business School, Jiangxi Normal University, Nanchang 330022, China)

Abstract: To take full advantage of the transfer characteristics of user behavior and alleviate the data sparsity of collected rating data, we propose a ranking based Bayesian sequence recommendation algorithm named SR-BPR. Firstly, SR-BPR build a tensor of user-item-item from users' historical interaction sequence relationship and then the user's preference ordering relation was built for each user. Finally, we use Bayesian ranking critical optimization algorithm for tensor decomposition. In this algorithm, we map user and item into a low dimensional space and make recommendation based on the latent factor vector of users. In the experiments with book crossing data, SR-BPR outperformance the traditional recommendation algorithm about 26% in term of precision, and the RMSE error rate reduced by 11.23% in the data density of 0.93% of 20% training data compare to the state-of-the-art methods.

Key words: recommendation algorithm; sequence recommendation; tensor decomposition; Bayesian network

1 引言

随着移动互联网技术的发展以及手持终端设备的普及,各种类型的互联网应用已经成为人类日常生活的必要组成部分,如移动购物、移动导航、移动新闻等。人类沉浸在无所不在的数字海洋,并以前所未有的便捷方式获取所需要的信息。然而,海量数字信息的产生也为人类信息筛选和甄别带来的巨大的挑战。近年来,随着大数据、机器学习、以及以深度学习为代表的的人工智能技术的发展与应用,在一定程度上缓解了人类筛选与甄别信息的时间与精力成本。

推荐系统作为典型的信息过滤技术,已经成为各大互联网应用的重要组成部分,如 FM 推荐、商品推荐、APP 推荐等。推荐系统的核心在于如何根据用户与互联网商品的复杂交互行为,建立用户-商品之间的潜在关系。当前的推荐算法主要以用户的商品购买行为建立二元实体关系,利用用户-用户、商品-商品之间的近邻关系产生推荐。基于二元实体关系的推荐算法面临以下问题:(a) 数据稀疏性,相对于海量的互联网产品和用户而言,可观测到的二元实体关系数据极为稀疏,从而导致较低的推荐精度。(b) 用户偏好静态性,将用户的历史

交互行为作为整体来预测用户偏好,忽略用户交互行为的时序特征。用户在做出某项决策之前往往会去对多个商品进行比较,而比较的过程反应了用户选择行为或偏好的变化,并对用户的最终决策产生显著影响。

为了缓解上述问题,国内外学者提出了多种改进的算法,如缺失值填充法、基于矩阵分解的推荐算法^[1]、基于影响集和云模型的协同过滤推荐算法等^[2]。这些算法仍然是基于二元稀疏数据矩阵,并没有完全解决数据稀疏性问题。近年来,上下文信息作为重要附属信息被越来越多的学者引入到推荐系统中,如基于卷积矩阵分解的内容推荐算法^[3]、基于元数据的上下文推荐算法^[4]、基于 LDA 的推荐算法等^[5]。虽然外部信息的引入可以缓解数据稀疏性问题,但是增加了计算复杂度。为了解决用户偏好的动态性,目前的研究成果主要集中于引入时间加权特征,即时间越近的行为对用户当前行为影响越大。然而,这些方法并没有考虑到用户行为的时序依赖特性。

为此,本文提出了基于 Ranking 的贝叶斯个性化序列推荐算法(SR-BPR)。算法首先基于用户与商品交互行为,建立用户-商品-商品的转移关系三维张量;其次,根据用户对商品

收稿日期: 2017-12-08 收修改稿日期: 2018-03-23 基金项目: 国家自然科学基金项目(71563030) 资助; 江西省教育厅科学技术研究项目(GJJ150370) 资助。 作者简介: 何 慧,女,1978 年生,硕士,讲师,研究方向为数据挖掘、大数据分析技术。

的序列转移关系, 构建用户偏好序列; 最后利用基于最大后验概率的贝叶斯 Ranking 排序算法对构造的三元转移关系张量进行分解. 由于本文的算法在对张量分解过程中充分利用了商品的转移关系特征, 可以充分利用观测到和未观测到的用户行为数据进行训练, 从而达到解决数据稀疏性的目的. 与传统的推荐算法相比, 本文提出的算法具有以下优点:

充分考虑了用户行为的时序动态特征, 基于用户的历史选择行为序列构造用户-商品-商品的三元转移关系张量.

提出了基于最大后验概率的贝叶斯 Ranking 排序算法的张量分解方法, 该方法通过转移序列关系进行参数优化, 充分利用观测和未观测行为数据, 在模型层面解决了数据稀疏性问题.

2 相关研究

总体而言, 推荐算法可以概括为两大类: 协同推荐和时序推荐算法. 协同推荐是建立在用户对商品的交互行为构建的用户-商品矩阵基础上, 这种交互行为包括浏览、购买、评价等. 然而, 相对与海量的互联网商品信息, 每个用户交互的商品数量是有限的, 这就导致数据的极端稀疏性, 进而导致用户或商品的相似度计算难以反映真实的内在关系. 为了解决数据的稀疏性问题, 国内外研究者提出了多种推荐算法, 如基于主成分分析的协同过滤推荐算法^[6]、基于影响集的协作过滤推荐算法^[2]、基于 k-均值层级聚类的推荐^[7]、基于概率矩阵分解的联合概率分布模型^[11]等. 这些算法均是基于用户对商品的评价建立评分矩阵, 并没有改变数据稀疏性的事实. 协同推荐的另一假设是将哪些没有明显交互行为的商品视为用户不喜欢的商品. 事实上, 用户未交互的商品并不全部代表用户不喜欢, 也有可能是该商品从未暴露给用户. 因此, 为了充分利用用户未观测到交互行为, 研究这提出了贝叶斯排序算法^[8], 将推荐评分预测问题转化为排序问题.

随着互联网信息的增加, 如商品描述信息、用户评价等, 越来越多的研究者开始将内容信息作为重要数据补充道推荐系统中, 与用户-商品的交互数据联合建模, 如基于用户-商品-标签散布图的推荐算法^[12]、内容的推荐算法^[9]、基于文档流的推荐算法^[10]. 这些推荐算法虽然在一定程度上缓解了数据稀疏性问题, 提升了推荐的精度, 但是并没有考虑用户行为的时序关系. 用户时序关系作为重要的数据信息, 在用户推荐, 特别是实时在线推荐中起到非常重要的作用, 因为用户的购买或观看行为往往存在一定的序列行为. 为了解决用户行为的时序问题, 国内外研究者提出了时序推荐这一新的研究领域, 并得到了学术界和工业界的广泛关注. 马尔科夫模型作为最为经典的时序关系模型, 逐渐被应用到推荐系统中^[11]. 基于马尔科夫假设, 研究者提出了多种算法, 如基于分解的个性化马尔科夫模型^[12]、基于类别转移的推荐算法^[13]等. 这些算法均是基于用户的行为转移关系, 构建一阶马尔科夫链, 然后预测行为转移概率. 近年来, 随着深度学习技术的发展, 越来越多的研究这深度学习方法, 如 LSTM、RNN、GRU 等融入到推荐系统中, 如基于内容的循环神经网络算法^[14]、基于 session 的序列推荐算法^[15]. 这些算法虽然在移动程度上利用了用户行为的转移时序关系, 但是会加剧数据的稀疏性. 为此, 本文提出了基于 Ranking 的贝叶斯序列推荐算法, 有效的

解决了用户行为的时序关系和数据稀疏性问题.

3 基于贝叶斯个性化排序的序列推荐算法

3.1 序列转移张量构建与分解

设 $U = \{u_1, u_2, \dots, u_M\}$ 为用户集合, $I = \{i_1, i_2, \dots, i_N\}$ 为商品集合. 用户 u 在 t 时刻之前购买/点击过的商品集合为 $I_u = \{I_u^1, I_u^2, \dots, I_u^{t-1}\}$, $I_u^{t-1} \in I$ 是商品集合的子集. 本文的目标是预测用户在 t 时刻可能会购买/浏览的商品集合. 基于一阶马尔科夫连假设, 用户在 t 时刻从当前浏览/购买的商品 i 到购买/浏览商品的概率表示为:

$$x_{u, i, j} = p(i \in I_u^t | j \in I_u^{t-1}) \quad (1)$$

因此, 每一个用户都对应于一个特定的商品转移矩阵, 从而生成一个三维转移关系张量 $\chi \in \mathbb{R}^{(M) \times (N) \times (N)}$, 每个元素取值 $\chi_{u, i, j}$ 表示观测到的用户从商品 i 到商品 j 的转移频率.

由于转移张量 χ 中只有少量的观测样本, 即数据稀疏性问题, 本文采用低阶张量分解模型对构造的三维转移关系张量进行分解, 然后利用矩阵恢复策略对缺失值进行填充预测. 张量中每个元素的恢复过程可以表示为:

$$\hat{x}_{u, i, j} = v_u^{U, K} \cdot p_j^{K, U} + v_j^{K, I} \cdot v_i^{I, K} + v_u^{U, J} \cdot v_i^{I, J} \quad (2)$$

其中, $v_u^{U, K}$ 和 $v_j^{K, J}$ 分别表示用户和下一个商品的潜在量. 由于 $v_u^{U, J}$ 和 $v_i^{I, J}$ 独立与下一个待预测商品 j , 并不影响最终的排序结果, 因此得到更加简洁的表达式为:

$$\hat{x}_{u, i, j} = v_u^{U, K} \cdot v_j^{K, J} + v_j^{K, I} \cdot v_i^{I, K} \quad (3)$$

由于下一个商品预测是得到 top-N 个商品, 而我们更关心的是候选商品的排序, 而非真实的转移概率取值. 因此, 我们把该问题转化为列表排序问题, 即:

$$j^{(1)} >_{u, j} \dots >_{u, j} j^{(k)} \Leftrightarrow \hat{x}_{u, i, j^{(1)}} > \dots > \hat{x}_{u, i, j^{(k)}} \quad (4)$$

$j^{(k)}$ 表示列表中的商品位置, $\hat{x}_{u, i, j^{(1)}}$ 表示用户 u 从商品 i 到商品 $j^{(1)}$ 的转移得分.

3.2 贝叶斯序列优化算法

本文使用基于列表的贝叶斯优化算法进行参数优化. 如果用户 u 从商品 i 转移到商品 j 的频率大于从商品 i 到商品 j' 的频率, 则认为用户对商品 j 的偏好程度大于对商品 j' 的偏好程度, 即 $j >_{u, j'} j'$. 基于此, 构造排序列表训练样本 $D_x = \{list_{u, i, j} | j^{(1)} >_{u, j} \dots >_{u, j} j^{(k)}\}$ 其中, k 表示列表长度. 寻找最优个性化排序的贝叶斯表示是最大化后验概率:

$$p(\Theta | list_{u, i, j}) \propto p(list_{u, i, j} | \Theta) p(\Theta) \quad (5)$$

其中, Θ 表示参数集合. 假设用户间的行为是相互独立的, 训练数据样本中的从当前商品下一个商品的转移行为也是相互独立的. 因此, 利用最大后验估计方法估计模型参数, 表示为:

$$\arg \max_{\Theta} \prod_{list_{u, i, j} \in D_x} p(list_{u, i, j} | \Theta) p(\Theta) \quad (6)$$

假设模型参数的先验概率服从正态分布, 即 $p(\Theta) \sim N(0, \frac{2}{\lambda_{\Theta}} I)$. 因此, 个性化排序的最大后验概率估计表示为:

$$\arg \max_{\Theta} \sum_{list_{u, i, j} \in D_x} \ln(p(list_{u, i, j} | \Theta)) - \frac{\lambda_{\Theta}}{2} \|\Theta\|^2 + C \quad (7)$$

$p(list_{u, i, j} | \Theta)$ 表示用户商品偏好列表的似然函数, 衡量了预测列表和真实列表之间的相似关系, 可以表示为:

$$p(\text{list}_{u,j} | \Theta) = \prod_{m=1}^k \frac{\phi(\hat{x}_{u,j(n)})}{\sum_{n=m}^k \phi(\hat{x}_{u,j(n)})} \quad (8)$$

其中 k 表示列表长度, $\phi(\cdot)$ 表示激活函数, $\phi(\cdot)$ 本文定义 $\phi(\cdot)$ 为指数函数. 通过整合公式 (8), 目标函数变化为:

$$\arg\max_{\Theta} \sum_{\text{list}_{u,j} \in D_x} \sum_{m=1}^k \{ \hat{x}_{u,j(n)} - \ln \sum_{n=m}^k \exp(\hat{x}_{u,j(n)}) \} - \frac{\lambda_{\Theta}}{2} \|\Theta\|^2 \quad (9)$$

利用地图下降法对公式 (9) 进行优化求解, 得到参数更新表达式为:

$$\Theta' = \Theta + \alpha \left(\frac{\partial}{\partial \Theta} \left(\ln(p(\text{list}_{u,j} | \Theta)) \right) - \frac{\lambda_{\Theta}}{2} \|\Theta\|^2 \right) \quad (10)$$

$\alpha > 0$, 表示学习率.

4 实验与结果分析

4.1 数据集

本文采用 Book Crossing 数据集进行实验分析. 该数据集由 Cai-Nicolas Ziegler 在 2004 年 8-9 月份用 4 周的时间从 Book crossing 社区采集到的, 共包含 278858 个用户, 271379 本图书, 1149780 条评分记录数据. 通过对用户的图书评分进行分析, 用户的评分行为服从幂律分布, 为了降低低频行为数据对实验结果的影响, 本实验剔除掉评分数量少于 20 个用户的图书, 以及评分数量小于 20 本图书的用户, 共得到 7369 个用户对 151537 本图书的 785814 条评分记录作为实验数据集.

4.2 评价指标

本文从评分预测和 TOP-N 推荐两个方面衡量推荐算法的准确度. 评分预测采用 RMSE(均方根误差) 衡量. RMSE 是通过计算预测的用户对商品评分与用户对该商品的真实评分之间的偏差来度量算法预测的准确性. RMSE 越小, 预测的越精确, 推荐精度也就越高. Top-N 采用准确度 (precision) 和召回率 (recall) 两个指标进行衡量. 假设用我们的算法预测用户对 k 个商品的评分为 $\{p_1, p_2, \dots, p_k\}$, 用户真实评分为 $\{r_1, r_2, \dots, r_k\}$, 则平均绝对误差表示为:

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^k |p_i - r_i|}{k}} \quad (11)$$

设 $R(u)$ 为用户 u 的推荐列表, $T(u)$ 为测试集中用户的真实行为数据记录. 则准确率 (precision) 和召回率 (recall) 的定义表示为:

$$\text{Precision} = \frac{\sum_{u \in U} |R(u) \cap T(u)|}{\sum_{u \in U} |R(u)|} \quad (12)$$

$$\text{Recall} = \frac{\sum_{u \in U} |R(u) \cap T(u)|}{\sum_{u \in U} |T(u)|} \quad (13)$$

4.3 实验设置与环境

将本文设计的算法与现有先进算法进行比较, 包括协同过滤推荐算法、TF(张量分解算法)、BPR 算法、MC-based 的推荐算法、MF 算法以及 PMF 进行比较. 由于本文构建的模型是基于用于转移矩阵, 因此, 对于 MF 和 PMF 两种算法, 本文将用户的商品浏览转移行为转化为二元商品转移对, 即: 如果用户

从商品 A 转移到商品 B, 则 $A \rightarrow B$ 为一个转移对. 构造用户-商品转移对之间的二维数据矩阵. 再在此基础上利用 MF 和 PMF 算法进行实验. 算法的参数 α 和 λ_0 分别设置为 0.1 和 0.01. 对比算法的参数按照原文献提供的最优参数进行设置.

为了验证模型的效果, 将用户评分记录按照时间进行排序, 选取前 70% 作为训练数据集, 后 20% 作为测试集, 中间的 10% 作为验证集进行实验. 实验在 4 核 Core(TM) i5-6400 CPU, 32G 内存服务器上运行, 为了避免实验的随机性, 采用十折交叉验证法进行实验. 首先在验证集上验证模型效果, 选取最佳参数, 最后在测试集上进行模型准确度测试. 最后取平均值作为实验结果.

4.4 实验结果与分析

4.4.1 预测结果比较

将本文提出的算法与对比算法进行实验, 实验结果如图 1、图 2 所示. 从图中可以看出, 随着推荐数量的增加, 推荐准确率呈递减趋势, 而推荐召回率呈上升趋势. 实验结果可以看




图 1 SR-BPR 算法与对比算法在 Book Crossing 数据集上的比较, 准确率随推荐数量的变化

Fig. 1 SR-BPR algorithm compared with the comparison algorithm in the Book Crossing data set precision with recommendations

出, 本文提出的 SR-BPR 推荐算法优于传统的推荐算法. 在推荐图书数量为 5 时, SR-BPR 算法的推荐准确率比 TF 算法提升了 26.5%, 召回率比 TF 算法提升了 63%. 这是由于本文提出的算法充分利用了用户偏好的偏序关系, 除了用户评分的图书外, 还充分利用了未评分图书数据, 在一定程度上缓解了数据的稀疏性.




图 2 SR-BPR 算法与对比算法在 Book Crossing 数据集上的比较, 召回率随推荐数量的变化

Fig. 2 SR-BPR algorithm compared with the comparison algorithm in the Book Crossing data set recall with recommendations

为了验证本文算法可以有效解决数据稀疏性问题, 进一步在不同稠密度的训练数据集上进行实验分析, 实验结果如

表 1 所示. 实验结果表明, MF 算法的误差最大, 其次是 PMF 算法. 这是由于 MF 和 PMF 算法只能作用在二维矩阵上, 为

了对用户行为转移进行分析, 必须将三维张量转化为用户序列转移对. 这样的话会导致用户行为转移关系的丢失. 基于三

表 1 不同算法在不同稀疏度训练集上的 RMSE 测量结果

Table1 RMSE measurement results of different algorithms on different sparse training sets

Model	不同比率的训练数据集							
	20% (0.93%)	30% (1.22%)	40% (1.56%)	50% (2.12%)	60% (2.58%)	70% (3.25%)	80% (3.84%)	60% (2.58%)
MF	1.4541	1.3832	1.3537	1.3054	1.2897	1.2764	1.2686	1.2897
PMF	1.3854	1.3076	1.2609	1.2587	1.2466	1.2231	1.1808	1.2466
TF	1.2542	1.2298	1.1812	1.1656	1.1434	1.1187	1.0998	1.1434
SR-BPR	1.1134	1.0851	0.9928	0.9709	0.9632	0.9565	0.9329	0.9632
improve	11.23%	11.77%	15.95%	16.7%	15.76%	14.50%	15.18%	15.76%

维张量的 TF 算法远远高于 MF 和 PMF 算法, 这是由于 TF 算法可以捕获用户-商品-商品之间的内在关系. 本文提出的 SR-BPR 算法 RMSE 误差远远小于传统的矩阵分解算法, 在稠密度为 50% 的数据集上, SR-BPR 算法误差率降低了 16.7%, 且随着数据稠密度的提升, RMSE 不断减小. 这是由于本文提出的算法充分利用了观测数据和未观测数据, 一定程度上缓解了数据的稀疏性问题.

4.4.2 序列长度影响分析

为了验证序列长度对推荐准确率和召回率的影响, 本文进一步进行实验分析, 研究在不同的序列长度下的推荐准确度和召回率. 序列长度以 1 为步长, 从 2 递增到 5, 实验结果如图 3、图 4 所示. 实验结果表明, 较大的序列长度产生较高

在增强.

5 总 结

本文提出了一种基于 Ranking 的贝叶斯序列推荐算法, 充分考虑用户商品浏览/购买过程的时序特性, 构建用户-商品-商品转移三维张量. 为了缓解三维张量中的数据稀疏性问题, 本文提出了基于 Ranking 的贝叶斯优化算法, 算法首先利用用户的商品转移概率构建偏序关系, 在此基础上利用 BPR 优化算法进行张量的分解. 通过张量分解, 将用户、商品映射到高维空间, 通过高维空间的用户与物品潜向量内积操作评估用户的商品偏好程度. 利用 Book Crossing 数据集进行实验分析, 实验结果表明, 本文提出的 SR-BPR 算法优于目前的推荐算法, 并且对于数据极端稀疏情况下仍然可以得到较好的结果.

References:

- [1] Lian De-fu, Zhao Cong, Xie Xing, et al. GeoMF: joint geographical modeling and matrix factorization for point-of-interest recommendation [C]. Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, New York, USA, August 24-27, 2014: 831-840.
- [2] Chen Jian, Yin Jiang. A collaborative filtering recommendation algorithm based on influence sets [J]. Journal of Software, 2007, 18 (7): 1685-1694.
- [3] Kim D, Park C, Oh J, et al. Convolutional matrix factorization for document context-aware recommendation [C]. Proceedings of the 10th ACM Conference on Recommender Systems, Boston, USA, September 15-19, 2016: 233-240.
- [4] Wang Dong-jing, Deng Shui-guang, Zhang Xin, et al. Learning music embedding with metadata for context aware recommendation [C]. Proceedings of the 2016 ACM on International Conference on Multimedia Retrieval, New York, USA, June 6-9, 2016: 249-253.
- [5] Krestel R, Fankhauser P, Nejdl W. Latent dirichlet allocation for tag recommendation [C]. Proceedings of the Third ACM Conference on Recommender Systems, New York, USA, October 22-25, 2009: 61-68.
- [6] Kim D, Yum B J. Collaborative filtering based on iterative principal component analysis [J]. Expert Systems with Applications, 2005, 28 (4): 823-830.
- [7] Papamichail G P, Papamichail D P. The k-means range algorithm for personalized data clustering in e-commerce [J]. European Journal of Operational Research, 2007, 177 (3): 1400-1408.
- [8] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian person-




图 3 序列长度对 SR-BPR 推荐效果影响, 准确度随推荐数量的变化

Fig.3 Length of the sequence influences the recommendation of SR-BPR, precision with recommendations




图 4 序列长度对 SR-BPR 推荐效果影响, 召回率随推荐数量的变化

Fig.4 Length of the sequence influences the SR-BPR recommendation, recall with recommendations

的推荐准确率和召回率. 当序列长度较小时, 推荐算法带来的算法提升相对有限. 随着序列长度的增大, 算法性能的提升也

- alized ranking from implicit feedback [C]. Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence, Montreal, Canada, June 18-21, 2009: 452-461.
- [9] Gao Hui-ji, Tang Ji-liang, Hu Xia, et al. Content-aware point of interest recommendation on location-based social networks [C]. Proceedings of the 29th Conference on Artificial Intelligence, Austin, Texas, USA, January 25-30, 2015: 1721-1727.
- [10] Djuric N, Wu Hao, Radosavljevic V, et al. Hierarchical neural language models for joint representation of streaming documents and their content [C]. Proceedings of the 24th International Conference on World Wide Web, Florence, Italy, May 18-22, 2015: 248-255.
- [11] Ahmed A A, Salim N. Markov chain recommendation system (MCRS) [J]. International Journal of Novel Research in Computer Science and Software Engineering, 2016, 3(1): 11-26.
- [12] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing person-item and item-item matrices for recommendation [C]. Proceedings of the 19th International Conference on World Wide Web, North Carolina, USA, April 26-30, 2010: 811-820.
- [13] He Jing, Li Xin, Liao Le-jian. Category-aware next point-of-interest recommendation via listwise Bayesian personalized ranking [C]. Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, Melbourne, Australia, August 19-25, 2017: 1721-1727.
- [14] Dai Han-jun, Wang Yi-chen, Trivedi R, et al. Recurrent coevolutionary latent feature processes for continuous-time recommendation [C]. Proceedings of the 1st Workshop on Deep Learning for Recommender Systems, Boston, USA, September 15, 2016: 29-34.
- [15] Hidasi B, Karatzoglou A, Baltrunas L, et al. Session-based recommendations with recurrent neural networks [J]. ArXiv Preprint ArXiv: 1511.06939, 2015.

征稿简则

一、征稿范围 《小型微型计算机系统》杂志刊登文章的内容涵盖计算技术的各个领域(计算数学除外)。包括计算机科学理论、体系结构、计算机软件、数据库、网络与通讯、人工智能、信息安全、多媒体、计算机图形与图像、算法理论研究等各方面的学术论文。

二、来稿要求: 本刊主要刊登下述各类原始文稿:

1. 学术论文: 科研成果的有创新、有见解的完整论述。对该领域的研究与发展有促进意义。
2. 综述: 对新兴的或活跃的学术领域或技术开发的现状及发展趋势的全面、客观的综合评述。
3. 技术报告: 在国内具有影响的重大科研项目的完整的技术总结。

三、注意事项

1. 来稿务求做到论点明确、条理清晰、数据可靠、叙述简练、词义通达。
2. 来稿必须是作者自己的科研成果, 无署名和版权争议。引用他人成果必须注明出处。
3. 本刊采用在线投稿方式, 可登陆 <http://xwxt.sict.ac.cn/> 进行在线投稿。
4. 格式要求: 题目(中、英文)、摘要(中、英文)、作者的真实姓名(中、英文)、作者的单位、城市(中、英文)、邮政编码、E-mail(便于联系的)、关键词(中、英文 4~7 个)、中图分类号、作者简介、基金项目。

(1) 英文部分的作者姓名使用汉语拼音, 单位英文名称须给出英文全称, 不要使用缩略语;

(2) 作者简介包含作者姓名、性别、出生年、最高学历、技术职称、研究方向(若作者中有中国计算机学会(CCF)会员, 请注明, 并给出会员号)。凡第一作者为 CCF 会员/高级会员/学生会员者, 将享受八五折的版面费优惠;

(3) 基金项目的类别与项目编号。

5. 中、英摘要: 文章摘要要具有独立性和自明性, 含正文等量的主要信息, 一般为 250~300 字, 采用第三人称表述。

6. 参考文献: 未公开发表的文献不得列入。文后所列参考文献统一排序, 且必须在正文中引用。中文参考文献应给出对应的英文译文。其具体书写格式为:

(1) 图书 [编号] 作者姓名(姓在前, 名在后), 书名, 出版社地址, 出版社, 出版年。

(2) 期刊 [编号] 作者姓名、文章题目、刊物名称, 出版年, 卷号(期号): 起止页码。

(3) 会议论文 [编号] 作者姓名, 论文题目, 见: 编者、论文集全名、出版地: 出版者, 出版年, 起止页码。

(4) 网络文献: 请给出文献作者或单位名, 文章题目、网址、发布日期。

7. 插图和表: 插图必须精绘并用计算机激光打印, 一般不超过 7 幅。图应结构紧凑, 不加底纹, 不要做成彩色的, 图宽最好不超过 8 厘米, 图内字号统一使用 6 号宋体, 字迹、曲线清晰, 必要时给出坐标名称和单位。每个图、表均给出中英文图注(如“图 1: *** 图” “Fig. 1: ***”)和表注(如“表 1: *** 表”, “Table 1: ***”)。

8. 计量单位: 稿件中一律使用《中华人民共和国法定计量单位》。外文和公式中应分清大、小写和正、斜体, 上、下角的字母、数码位置准确。易混淆的字母或符号, 请在第一次出现时标注清楚。

9. 本刊在收到作者稿件经初审后立即给作者电子邮箱发“稿件收到通知”。除作者另有明确要求外, 本刊原则上只与第一作者联系, 作者投稿后若 4 个月无消息, 可自行改投它刊。通过初审的稿件将收到本刊给予的编号, 并需邮寄审稿费。

10. 本刊对不拟录用的稿件只发给“退稿通知”, 恕不退回原稿, 请自留底稿。

11. 稿件一经发表, 将酌致稿酬, 并寄送样刊。

本刊文章现被国内外多家数据库收录, 作者著作权使用费与本刊稿酬一并给付, 作者若不同意将文章收录, 请在投稿时说明。

编辑部地址: 沈阳市浑南区南屏东路 16 号《小型微型计算机系统》编辑部 邮政编码: 110168

电话: (024) 24696120 E-mail: xwxt@sict.ac.cn 网址: <http://xwxt.sict.ac.cn>